

教育背景

2027.06 (预计)	北京大学，软件与微电子学院，关键软件，在读硕士生 GPA: 3.73/4.00 (RANK: top 2.51%) 引用: 211 H-index: 6 (May 2026) 主修课程: 深度学习技术与应用 (A+), 机器学习 (A+), 软件工程技术专题 (A+), 软件实现技术 (A+), 学术英语写作 (A+)	北京
2024.06	华南理工大学，软件学院，软件工程，工学学士 GPA: 3.89/4.00 (RANK: top 1.61%) 主修课程: 机器学习 (93), 微积分 (92), 概率与数理统计 (92), 智能软件项目实训 (93), 高级语言程序设计 (96), C++ 程序开发实训 (100)	广州

代表性论文

- [1] [From Blind Spots to Gains: Diagnostic-Driven Iterative Training for Large Multimodal Models](#)
Hongrui Jia, Chaoya Jiang, Yongrui Heng, Shikun Zhang, Wei Ye
International Conference on Machine Learning (ICML 2026) [🔗 Code](#)
- [2] [OSWorld-MCP: Benchmarking MCP Tool Invocation In Computer-Use Agents](#)
Hongrui Jia, Jitong Liao, Xi Zhang, Haiyang Xu, Tianbao Xie, Chaoya Jiang, Ming Yan, Si Liu, Wei Ye, Fei Huang
International Conference on Learning Representations (ICLR 2026) [🔗 Code](#)
- [3] [Mitigating Visual Context Degradation in Large Multimodal Models: A Training-Free Decoupled Agentic Framework](#)
Hongrui Jia, Chaoya Jiang, Shikun Zhang, Wei Ye
Computer Vision and Pattern Recognition Conference (CVPR 2026) [🔗 Code](#)
- [4] [SymDPO: Boosting In-Context Learning of Large Multimodal Models with Symbol Demonstration Direct Preference Optimization](#)
Hongrui Jia, Chaoya Jiang, Haiyang Xu, Wei Ye, Mengfan Dong, Ming Yan, Ji Zhang, Fei Huang, Shikun Zhang
Computer Vision and Pattern Recognition Conference (CVPR 2025) [🔗 Code](#)
- [5] [MaVEn: An Effective Multi-Granularity Hybrid Visual Encoding Framework for Multimodal Large Language Model](#)
Chaoya Jiang*, Hongrui Jia* (*Equal Contribution), Haiyang Xu, Wei Ye, Mengfan Dong, Ming Yan, Ji Zhang, Fei Huang, Shikun Zhang
Advances in Neural Information Processing Systems (NeurIPS 2024) [🔗 Code](#)

[6] **Hal-eval: A Universal and Fine-grained Hallucination Evaluation Framework for Large Vision Language Models**
Chaoya Jiang*, **Hongrui Jia*** (*Equal Contribution), Mengfan Dong, Wei Ye, Haiyang Xu, Ming Yan, Ji Zhang, Shikun Zhang
ACM International Conference on Multimedia (ACM MM 2024), **Oral**

[7] **ISC4DGF: Enhancing Directed Grey-box Fuzzing with LLM-Driven Initial Seed Corpus Generation**
Yijiang Xu, **Hongrui Jia**, Liguo Chen, Xin Wang, Zhengran Zeng, Yidong Wang, Qing Gao, Jindong Wang, Wei Ye, Shikun Zhang, Zhonghai Wu
Journal of computer science and technology (JCST)

代表性荣誉

2025.10	国家奖学金	中国国家教育部
2021.10	国家奖学金	中国国家教育部
2022.12	2022CCF 大数据与计算智能大赛系统访问风险识别赛题前 4.28%担任队长	中国计算机学会
2024.6	“富途杯” 软件文化设计大赛决赛第四名	富途科技有限公司
2024.6	2023 年国家级大学生创新创业训练计划项目《基于联邦学习的个性化句子分类技术研究》优秀结项	中国国家教育部

实习经历

阿里巴巴通义实验室	北京
研究型实习生	2025.06 – 2026.04
- 随着 MCP 能力的重要性日益凸显，现有的 GUI 基准却未纳入 MCP 工具，导致评估缺乏公平性。为此，我构建了 OSWorld-MCP 基准，用于全面评估计算机使用代理在 MCP 工具调用、GUI 交互和决策能力方面的表现。 - 负责构建 Mobile-Agent-v3 数据生成流程中的 critic 框架。通过多轮提问与投票机制，critic 框架的采集数据成功率超过 90%。 - 持续探索提升模型工具调用能力的方法。	

学术服务

会议审稿人:	CVPR (2026), ICLR (2026), EMNLP (2025), ACL (2025), NAACL (2025)
开源服务:	OSWorld-MCP 框架的维护者；开源 VLM 训练方法 SymDPO 的贡献者。

科研经历

Research Vision:

My research focuses on **improving the reliability of multimodal reasoning in MLLMs and agents**. I study how to diagnose failure modes in multimodal reasoning, enforce evidence-grounded reasoning processes, and improve model capabilities through diagnostic-driven training. My goal is to **build multimodal AI systems that can reason reliably in complex open-world environments**.

- 当前多模态大语言模型的推理能力提升离不开高质量的数据，而“自进化 (self-evolving) 数据生成范式”解决了人工标注成本高的问题，即通过模型自身生成训练数据并持续迭代优化。然而，现有方法普遍存在一个关键问题：它们在生成数据时缺乏对模型失败模式的明确建模与诊断，导致生成的数据往往缺乏针对性，容易出现低质量、低多样性甚至语义无效的问题。这种“无诊断的进化”使得模型难以持续提升，甚至在迭代过程中出现性能震荡或退化。因此，如何从模型的真实能力缺陷出发，构建高质量、可验证、针对性的训练数据，是当前 MLLM 持续优化中的核心挑战。为了解决这一问题，我们提出了 DPE (Diagnostic-driven Progressive Evolution)，一个以“显式失败诊断”为核心的多模态模型进化框架。其核心思想是：在每一轮迭代中，首先对模型在不同能力维度上的失败进行结构化诊断（如数学理解、图表推理、空间认知等），然后基于这些诊断结果指导数据生成、数据分配与模型训练，从而实现针对性、可控的能力提升。相比于传统自进化方法，DPE 不仅关注“生成更多数据”，更关注“生成正确的数据”，采用 GRPO 等强化学习方法，仅依赖最终答案的可验证信号进行训练，避免对教师模型输出的模仿。此外，我们还设计了诊断驱动的数据混合策略，使模型在不同能力维度上的训练分布能够动态调整，从而实现持续稳定的性能提升。
- 我在该工作中的主要贡献包括：提出诊断驱动的数据生成与训练范式，系统性设计并实现 DPE 框架；构建多模态失败模式分类体系，并验证其对训练效果的稳定性与鲁棒性；设计结合外部工具的视觉数据构造机制，显著提升生成样本的质量与多样性；提出基于可验证信号的强化学习训练策略，避免传统蒸馏带来的偏差；并通过系统的消融实验与人类评估，验证各个模块在持续进化过程中的关键作用。
- 该工作产出一篇论文，我为论文的**第一作者**。

OSWorld-MCP: Benchmarking MCP Tool Invocation In Computer-Use Agents 2025.07 - 2025.09

- 过去的 computer-use agents 评估主要侧重于 GUI 交互能力，而工具调用能力（例如由模型上下文协议 (MCP) 实现的工具调用能力）则在很大程度上被忽视。将集成工具调用能力的智能体与仅评估 GUI 交互能力的智能体进行比较本质上是不公平的。我们提出了 OSWorld-MCP，这是第一个全面且公平的基准测试，用于评估计算机应用智能体在现实环境中的工具调用、GUI 操作和决策能力。在 OSWorld-MCP 上对最先进的多模态代理进行的广泛评估表明，MCP 工具通常能够提高任务成功率，这凸显了评估工具调用能力的重要性。然而，即使是最强大的模型，其工具调用率也相对较低，凸显了基准测试的挑战性。
- 我设计了一种新颖的自动化代码生成流程来创建工具，并将其与从现有工具中精选的工具相结合。经过严格的人工验证，我们最终筛选出 158 种高质量工具（涵盖 7 种常见应用程序），每种工具都经过了功能性验证、实用性和多功能性验证。我将筛选出的 MCP Tools 接入到 OSWorld-MCP 框架中，并进行了广泛的实验，我还负责了整篇论文的写作。
- 该工作产出一篇论文，我为论文的**第一作者**。

Mitigating Visual Context Degradation in Large Multimodal Models: A Training-Free Decoupled Agentic Framework 2025.03 - 2025.09

- 随着推理链的延伸，多模态大语言模型 (LMM) 越来越依赖于文本逻辑，逐渐失去对底层视觉信息的理解。这导致推理路径偏离图像内容，最终得出错误的结论。为了解决这个问题，我们引入了一个极其简单但有效的无需训练的视觉推理流程。其核心理念是将推理过程与感知过程分离。这种轻量级、即插即用的方法无需额外的训练或架构变更。全面的评估验证了我们的框架能够有效地控制视觉推理过程，从而显著减少了视觉上毫无根据的推理步骤，并显著提高了推理保真度。

- 我设计了 LLM Reasoner 和 LMM Observer 两个模块，LLM Reasoner 通过强大的 LLM 能够协调高级推理，策略性地询问 LMM，以提取其逻辑链所需的特定视觉信息。反过来，LMM Observer 通过 LMM 则专门用作视觉问答引擎，按需提供必要的感知细节。通过广泛的实验，我验证了链路的有效性。
- 该工作产出一篇论文，已被 **CVPR2026** 接收，我为论文的**第一作者**。

SymDPO: Boosting In-Context Learning of Large Multimodal Models with Symbol Demonstration Direct Preference Optimization 2024.06 - 2024.11

- 现有的大型多模态模型（LMMs）在上下文学习（ICL）中存在过于依赖文本模式匹配而忽视视觉上下文的问题，而未能有效利用视觉信息，导致模型在多模态任务中表现不佳。现有的多模态上下文学习方法主要依赖于大规模的图像-文本数据预训练或专门的指令微调数据集，但这些方法仍然存在视觉上下文忽视的问题。虽然 DPO 方法已被用于提升模型的指令遵循能力，但现有的 DPO 方法主要针对通用指令任务，缺乏专门针对多模态上下文学习中视觉和文本信息融合的机制。此外，收集可靠的多模态偏好数据也面临挑战，因为许多问题可以通过文本信息单独回答，而不需要依赖视觉上下文。我们提出符号演示直接偏好优化（SymDPO）方法，将演示中的文本答案替换为符号，构建特殊的 SymDPO 数据集，并基于直接偏好优化（DPO）技术对模型进行训练，增强模型对视觉信息的利用和视觉-文本信息的融合。实验表明，SymDPO 在多个基准测试中显著提升了模型性能，与现有 DPO 方法相比效果更优，且消融实验进一步验证了其对视觉上下文的依赖和符号替换策略的有效性。
- 我收集图片-问-答，整理成 ICL 格式的数据，并进一步构建成 DPO 数据，最后替换一定比例的数据中的回答为随机符号，创建 SymDPO 数据。之后，我利用 SymDPO 数据集训练模型进行了实验和消融实验，验证了 SymDPO 方法的优越性和有效性，最后我进行了论文的撰写工作。
- 该工作产出一篇论文，已被 **CVPR2025** 接收，其中我为论文的**第一作者**。

Hal-eval: A universal and fine-grained hallucination evaluation framework for large vision language models 2023.11 - 2024.04

- 大型视觉语言模型存在“幻觉”问题，幻觉问题严重影响了 LVLMS 的可靠性和鲁棒性，限制了其在实际应用中的部署。以往的研究主要关注对象、属性和关系方面的幻觉，但忽略了更复杂的幻觉类型，例如围绕虚构实体构建整个叙事的事件幻觉。目前缺乏对这类幻觉的细粒度评估基准。因此，需要一个更全面、细粒度的幻觉评估框架，以更好地理解和改进 LVLMS 在处理幻觉方面的能力。
- 我们引入事件幻觉，并提出了通用细粒度的幻觉评估框架 Hal-eval，通过设计自动标注管道生成包含多种幻觉类型的标注数据，并结合判别式和生成式评估方法，全面评估大型视觉语言模型处理幻觉的能力。
- 通过实验，我们发现现有 LVLMS 在处理事件幻觉方面存在显著不足，且幻觉发生率随输出长度增加而上升；使用链式思考（COT）能有效减少判别式评估中的幻觉，而生成式评估更能准确反映模型在事件幻觉上的表现，且通过幻觉标注数据进行监督微调可显著提升模型性能。
- 我在该项目中设计了一个自动细粒度幻觉标注管道（AFHA），利用 GPT-4 和强大能力，对图像文本对进行标注，生成包含对象、属性、关系和事件幻觉的详细标注数据。同时，我还负责了 Hal-eval 中的生成式评估框架及实验部分。
- 该工作产出一篇论文，已被 **MM2024** 接受为 **Oral(top 4%)** 的工作，其中我为论文的**共同第一作者**。

Maven: An effective multi-granularity hybrid visual encoding framework for multimodal large language model 2024.02 - 2024.05

- 当前多模态大语言模型（MLLMs）主要专注于单张图片的理解，难以有效整合和解释多张图片中的信息，限制了其在多图场景下的应用能力。现实世界中许多任务涉及多张图片，这些任务要求模型能够跨多张图片理解和整合信息，而现有的单图视觉编码方法无法满足这一需求。当前的视觉特征编码方法主要有两种，一种是基于离散符号编码，另一种是基于连续序列编码。离散符号编码虽然能够提供高层次的语义抽象，但粒度过粗，容易丢失细节；连续序列编码虽然能够捕捉图像细节，但在多图场景下会导致序列过长，增加计算负担，并且与文本表示的对齐不够精确。因此，我们提出了 MaVE_n，一个多粒度混合视觉编码框架，通过结合离散视觉符号序列（用于高层次语义抽象）和连续视觉序列（用于细节特征捕捉），并设计动态压缩机制减少冗余特征，提升多图处理效率。实验表明，MaVE_n 显著提升了多模态大语言模型在多图场景下的性能，例如在 DemonBench 和 SEED-Bench 基准测试中均优于现有模型，同时也在单图场景下表现出色，验证了其在多模态任务中的有效性。
- 我设计并实现了多粒度混合编码，分别使用 SEED 和 ViT 对图像进行离散编码和连续编码，合并词表使模型能够同时处理两种编码，并根据模型结构，设计了四阶段训练，对 MaVE_n 的性能在多种多图和单图测试中进行了广泛的评估，并进行消融实验验证了方法的有效性。
- 该工作产出一篇论文，已被 **NeurIPS2024** 接收，其中我为论文的**共同第一作者**。

ISC4DGF: Enhancing Directed Grey-box Fuzzing with LLM-Driven Initial Seed Corpus Generation 2024.06 - 2025.03

- 定向灰盒模糊测试（DGF）在检测特定软件漏洞时效率受限，因初始种子语料库设计不足，影响漏洞触发速度和成功率。我们希望利用大型语言模型（LLM）强大的代码理解和生成能力，优化初始种子语料库，提升 DGF 的效率和准确性。因此，我们提出 ISC4DGF，通过 LLM 优化用户输入并生成高质量种子，替换默认种子库，引导模糊测试更高效地触发目标漏洞。ISC4DGF 在 Magma 基准测试中表现卓越，平均速度提升 35.63 倍，目标触发次数减少 616.10 倍，显著优于现有顶级模糊测试工具。
- 我设计并实现了 LLM 生成优化的初始种子语料库的流程，我使用一个 LLM 根据输入生成简洁且信息丰富的提示，将优化后的提示输入到 LLM 中，生成多种可能的种子输入。
- 该工作产出一篇论文，已被 **JCST** 接收，其中我为论文的**第二作者**。